

# РАЗЛОЖЕНИЕ ОШИБКИ (BIAS-VARIANCE DECOMPOSITION)

Зачастую для улучшения качества модели необходимо понять, из-за чего возникает ошибка в предсказаниях.

**Утверждение:** ошибку модели  $a(x)$  можно представить в виде

$$\text{Err}(x) = \text{Bias}^2(a(x)) + \text{Var}(a(x)) + \sigma^2.$$

# РАЗЛОЖЕНИЕ ОШИБКИ (BIAS-VARIANCE DECOMPOSITION)

Зачастую для улучшения качества модели необходимо понять, из-за чего возникает ошибка в предсказаниях.

**Утверждение:** ошибку модели  $a(x)$  можно представить в виде

$$\text{Err}(x) = \text{Bias}^2(a(x)) + \text{Var}(a(x)) + \sigma^2.$$

# РАЗЛОЖЕНИЕ ОШИБКИ (BIAS-VARIANCE DECOMPOSITION)

Зачастую для улучшения качества модели необходимо понять, из-за чего возникает ошибка в предсказаниях.

**Утверждение:** ошибку модели  $a(x)$  можно представить в виде

$$\text{Err}(x) = \text{Bias}^2(a(x)) + \text{Var}(a(x)) + \sigma^2.$$

- **$\text{Bias}(a(x))$**  - средняя ошибка по всем возможным наборам данных – **смещение**.

# РАЗЛОЖЕНИЕ ОШИБКИ (BIAS-VARIANCE DECOMPOSITION)

Зачастую для улучшения качества модели необходимо понять, из-за чего возникает ошибка в предсказаниях.

**Утверждение:** ошибку модели  $a(x)$  можно представить в виде

$$\text{Err}(x) = \text{Bias}^2(a(x)) + \text{Var}(a(x)) + \sigma^2.$$

- $\text{Bias}(a(x))$  - средняя ошибка по всем возможным наборам данных – **смещение**.

*Смещение показывает, насколько в среднем модель хорошо предсказывает целевую переменную:*

- ✓ *маленькое смещение - хорошее предсказание*
- ✓ *большое смещение – плохое предсказание*

# РАЗЛОЖЕНИЕ ОШИБКИ (BIAS-VARIANCE DECOMPOSITION)

Зачастую для улучшения качества модели необходимо понять, из-за чего возникает ошибка в предсказаниях.

**Утверждение:** ошибку модели  $a(x)$  можно представить в виде

$$\text{Err}(x) = \text{Bias}^2(a(x)) + \text{Var}(a(x)) + \sigma^2.$$

- **$\text{Var}(a(x))$**  - дисперсия ошибки, т.е. как сильно различается ошибка при обучении на различных наборах данных – **разброс**.

# РАЗЛОЖЕНИЕ ОШИБКИ (BIAS-VARIANCE DECOMPOSITION)

Зачастую для улучшения качества модели необходимо понять, из-за чего возникает ошибка в предсказаниях.

**Утверждение:** ошибку модели  $a(x)$  можно представить в виде

$$\text{Err}(x) = \text{Bias}^2(a(x)) + \text{Var}(a(x)) + \sigma^2.$$

- $\text{Var}(a(x))$  - дисперсия ошибки, т.е. как сильно различается ошибка при обучении на различных наборах данных – **разброс**.

*Большой разброс означает, что ошибка очень чувствительна к изменению обучающей выборки, т.е.:*

✓ *большой разброс – сильно переобученная модель*

# РАЗЛОЖЕНИЕ ОШИБКИ (BIAS-VARIANCE DECOMPOSITION)


Зачастую для улучшения качества модели необходимо понять, из-за чего возникает ошибка в предсказаниях.

**Утверждение:** ошибку модели  $a(x)$  можно представить в виде

$$\text{Err}(x) = \text{Bias}^2(a(x)) + \text{Var}(a(x)) + \sigma^2.$$


- **$\text{Bias}(a(x))$**  - средняя ошибка по всем возможным наборам данных – **смещение**.
- **$\text{Var}(a(x))$**  - дисперсия ошибки, т.е. как сильно различается ошибка при обучении на различных наборах данных – **разброс**.
- **$\sigma^2$**  - неустраняемая ошибка – **шум**.

# СМЕЩЕНИЕ И РАЗБРОС





# BIAS-VARIANCE TRADEOFF




# БУТСТРЭП

Дана выборка  $X$ .

**Бутстрэп:** равномерно возьмем из выборки  $X$   $l$  объектов с возвращением (т.е. в новой выборке будут повторяющиеся объекты). Получим выборку  $X_1$ .

- Повторяем процедуру  $N$  раз, получаем выборки  $X_1, \dots, X_N$ .



# БЭГГИНГ (BOOTSTRAP AGGREGATION)


С помощью бутстрэпа мы получили выборки  $X_1, \dots, X_N$ .

- Обучим по каждой из них модель – получим базовые алгоритмы  $b_1(x), \dots, b_N(x)$ .
- Построим новую функцию регрессии:

$$a(x) = \frac{1}{N} \sum_{j=1}^N b_j(x)$$

# БЭГГИНГ (BOOTSTRAP AGGREGATION)

$$a(x) = \frac{1}{N} \sum_{j=1}^N b_j(x)$$



# РАЗЛОЖЕНИЕ ОШИБКИ (BIAS-VARIANCE DECOMPOSITION)

Зачастую для улучшения качества модели необходимо понять, из-за чего возникает ошибка в предсказаниях.

- *Модель переобучена?*
- *Модель плохо предсказывает целевую переменную?*
- *В самих данных много неточностей (шумов)*

# СМЕЩЕНИЕ И РАЗБРОС У БЭГГИНГА

Бэггинг: 
$$a_N(x) = \frac{1}{N} \sum_{n=1}^N b_n(x) = \frac{1}{N} \sum_{n=1}^N \tilde{\mu}(X)(x)$$

(здесь  $\tilde{\mu}(X) = \mu(\tilde{X})$  – алгоритм, обученный на подвыборке  $\tilde{X}$ )


**Утверждение (с док-вом):**

**1) Бэггинг не ухудшает смещенность модели, т.е. смещение  $a_N(x)$  равно смещению одного базового алгоритма.**

**2) Если базовые алгоритмы некоррелированы, то дисперсия бэггинга  $a_N(x)$  в  $N$  раз меньше дисперсии отдельных базовых алгоритмов.**

# СЛУЧАЙНЫЙ ЛЕС (RANDOM FOREST)

- Возьмем в качестве базовых алгоритмов для бэггинга **решающие деревья**, т.е. каждое случайное дерево  $b_i(x)$  построено по своей подвыборке  $X_i$ .
- В каждой вершине дерева будем искать **разбиение не по всем признакам, а по подмножеству признаков**.
- Дерево строится до тех пор, пока в листе не окажется  $n_{min}$  объектов.



# RANDOM FOREST

---

## Алгоритм 3.1. Random Forest

---

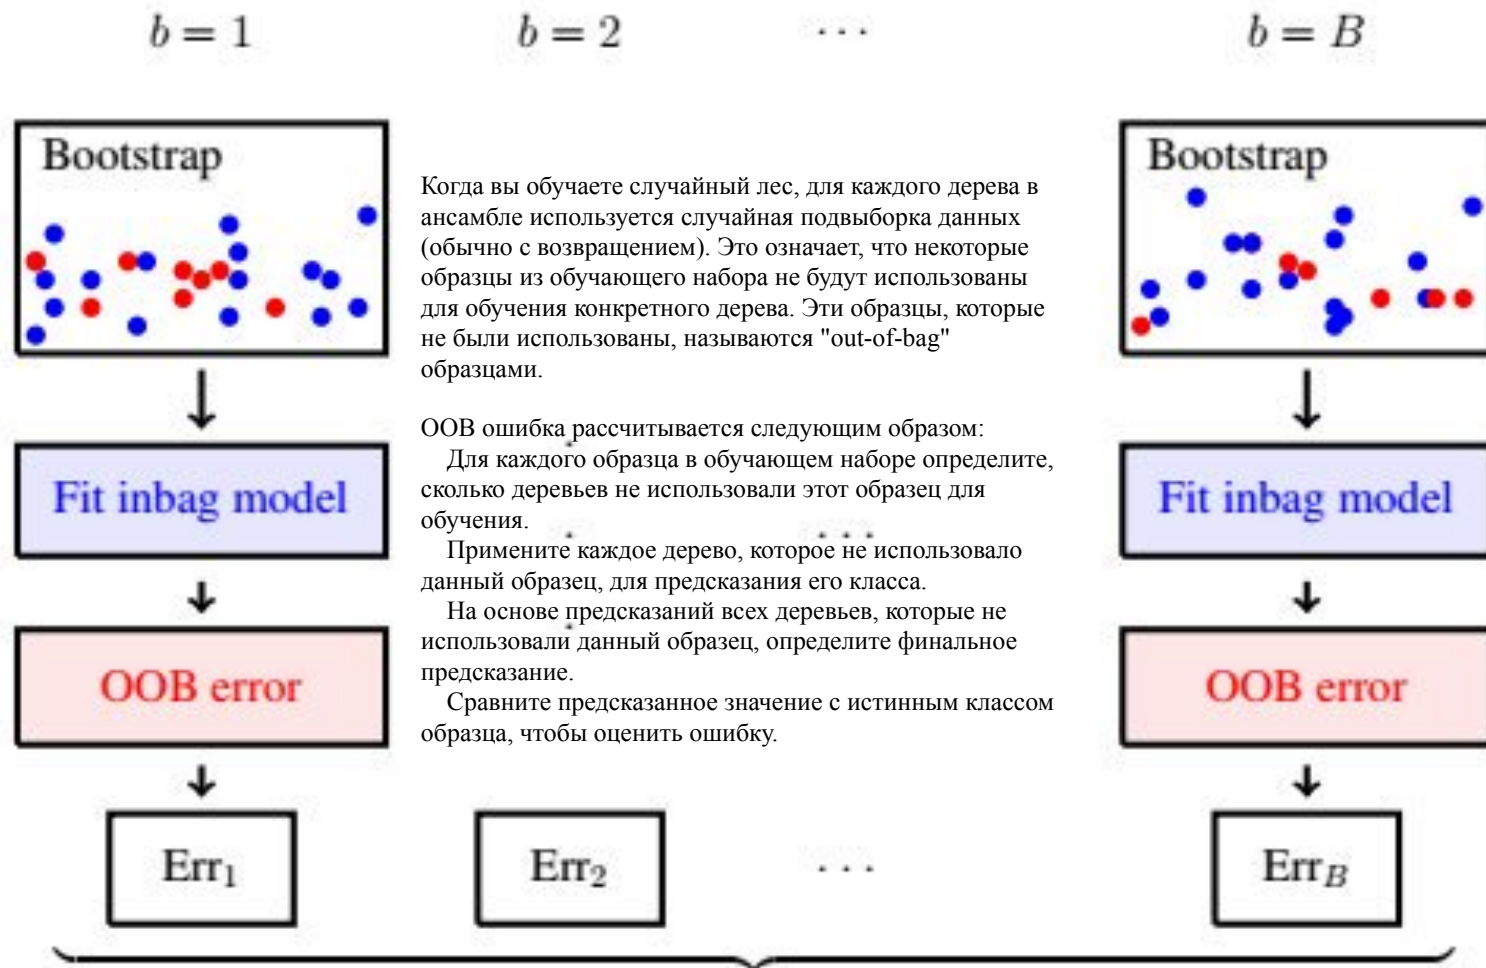
- 1: для  $n = 1, \dots, N$
  - 2: Сгенерировать выборку  $\tilde{X}_n$  с помощью бутстрэпа
  - 3: Построить решающее дерево  $b_n(x)$  по выборке  $\tilde{X}_n$ :
    - дерево строится, пока в каждом листе не окажется не более  $n_{\min}$  объектов
    - при каждом разбиении сначала выбирается  $m$  случайных признаков из  $p$ , и оптимальное разделение ищется только среди них
  - 4: Вернуть композицию  $a_N(x) = \frac{1}{N} \sum_{n=1}^N b_n(x)$
-



# RANDOM FOREST – ПРАКТИЧЕСКИЕ РЕКОМЕНДАЦИИ

- Если  $p$  – количество признаков, то при классификации обычно берут  $m = \lfloor \sqrt{p} \rfloor$ , а при регрессии -  $m = \lfloor \frac{p}{3} \rfloor$  признаков
- При классификации обычно дерево строится, пока в листе не окажется  $n_{min} = 1$  объект, а при регрессии  $n_{min} = 5$

# OUT-OF-BAG ОШИБКА



$$\text{Err}_{\text{oob}} = \frac{\text{Err}_1 + \dots + \text{Err}_B}{B} = \frac{1}{B} \sum_{b=1}^B \text{Err}_b$$

# OUT-OF-BAG ОШИБКА

- Каждое дерево в случайном лесе обучается по некоторому подмножеству объектов
- Значит, для каждого объекта есть деревья, которые на этом объекте не обучались.


Out-of-bag ошибка:

$$OOB = \sum_{i=1}^l L(y_i, \frac{\sum_{n=1}^N [x_i \notin X_n] b_n(x_i)}{\sum_{n=1}^N [x_i \notin X_n]})$$

**Утверждение.** При  $N \rightarrow \infty$   $OOB$  оценка стремится к *leave-one-out* оценке.

# OOB-SCORE

По графику out-of-bag ошибки можно, например, подбирать количество деревьев в случайном лесе



# КАЛИБРОВКА ВЕРОЯТНОСТЕЙ

**Калибровка вероятностей** - приведение ответов алгоритма к значениям, близким к вероятностям объектов принадлежать конкретному классу.

Зачем это нужно?

- Вероятности гораздо проще интерпретировать
- Вероятности могут дать дополнительную информацию о результатах работы алгоритма

# КАЛИБРОВКА ПЛАТТА

- Пусть есть два класса,  $Y = \{+1, -1\}$

**Задача:** для классификатора  $a(x)$ , предсказывающего значения из отрезка  $[0, 1]$ , либо предсказывающего класс (+1 или -1), сделать калибровку, чтобы предсказания были вероятностями  $p(y = +1|x)$ .


# КАЛИБРОВКА ПЛАТТА

- Пусть есть два класса,  $Y = \{+1, -1\}$

**Задача:** для классификатора  $a(x)$ , предсказывающего значения из отрезка  $[0, 1]$ , либо предсказывающего класс (+1 или -1), сделать калибровку, чтобы предсказания были вероятностями  $p(y = +1|x)$ .

**Идея:** обучаем логистическую регрессию на ответах классификатора  $a(x)$ .

# ПРИМЕР ИЗ SKLEARN





# КАЛИБРОВКА ПЛАТТА

- Пусть есть два класса,  $Y = \{+1, -1\}$

**Задача:** для классификатора  $a(x)$ , предсказывающего значения из отрезка  $[0, 1]$ , либо предсказывающего класс (+1 или -1), сделать калибровку, чтобы предсказания были вероятностями  $p(y = +1|x)$ .

**Идея:** *обучаем логистическую регрессию на ответах классификатора  $a(x)$ .*

# КАЛИБРОВКА ПЛАТТА

- Пусть есть два класса,  $Y = \{+1, -1\}$

**Задача:** для классификатора  $a(x)$ , предсказывающего значения из отрезка  $[0, 1]$ , либо предсказывающего класс (+1 или -1), сделать калибровку, чтобы предсказания были вероятностями  $p(y = +1|x)$ .

**Идея:** *обучаем логистическую регрессию на ответах классификатора  $a(x)$ .*

- $$\pi(x; \alpha; \beta) = \sigma(\alpha \cdot a(x) + \beta) = \frac{1}{1 + e^{-(\alpha \cdot a(x) + \beta)}}$$

# КАЛИБРОВКА ПЛАТТА

- Пусть есть два класса,  $Y = \{+1, -1\}$

**Задача:** для классификатора  $a(x)$ , предсказывающего значения из отрезка  $[0, 1]$ , либо предсказывающего класс (+1 или -1), сделать калибровку, чтобы предсказания были вероятностями  $p(y = +1|x)$ .

**Идея:** *обучаем логистическую регрессию на ответах классификатора  $a(x)$ .*

- $\pi(x; \alpha; \beta) = \sigma(\alpha \cdot a(x) + \beta) = \frac{1}{1 + e^{-(\alpha \cdot a(x) + \beta)}}$
- Находим  $\alpha$  и  $\beta$ , минимизируя логистическую функцию потерь (*то есть обучаем логистическую регрессию*):

$$- \sum_{y_i = -1} \log(1 - \pi(x; \alpha; \beta)) - \sum_{y_i = +1} \log(\pi(x; \alpha; \beta)) \rightarrow \min_{\alpha, \beta}$$